

VitalRisk AI

Sistema Inteligente de Vigilancia Preventiva Territorial en Salud

EQUIPO 326

FASE 1 · SPRINT 2

DATOS AL ECOSISTEMA 2026

JUNIO 2026

1. ¿Qué es VitalRisk AI?

VitalRisk AI es una plataforma de inteligencia artificial que convierte datos públicos oficiales en alertas preventivas de salud para el Valle de Aburrá y Antioquia. No diagnostica enfermedades: las **anticipa**. Detecta cuándo una combinación de mala calidad del aire, condiciones climáticas y vulnerabilidad social puede desencadenar un brote de enfermedades respiratorias en un municipio, con al menos una semana de anticipación.

EL PROBLEMA	LA SOLUCIÓN
Las enfermedades respiratorias (IRA) afectan a miles de personas en el Valle de Aburrá cada año. Las alertas del sistema de salud llegan cuando ya hay brote, no antes. No existe hoy un sistema público que integre calidad del aire, epidemiología y datos sociales para predecir dónde y cuándo ocurrirá el próximo pico.	VitalRisk AI cruza datos de PM2.5/PM10 (SIATA/IDEAM), casos de IRA (SIVIGILA/INS) y datos socioeconómicos (DANE). Calcula un Índice Preventivo Territorial (IPT) por municipio y usa un modelo de Machine Learning (XGBoost) para generar alertas de riesgo con una semana de anticipación.

2. ¿Qué tenemos construido hoy?

El equipo completó la **Épica 1 (Infraestructura)** y está en la **Épica 2 (Pipelines de datos)**. El sistema ya tiene cimientos técnicos sólidos sobre los cuales se construirá el modelo de IA.

Historia de Usuario	Épica	Estado	¿Qué hace?
HU1 — Entorno Docker	É1 Infraestructura	✓ LISTO	Servidor corriendo en contenedores reproducibles. Cualquier computador del equipo levanta el proyecto con un solo comando.
HU2 — ADR Arquitectura	É1 Infraestructura	✓ LISTO	Documento formal que justifica por qué se eligió cada tecnología (FastAPI, PostgreSQL, Docker). Incluye diagrama del flujo de datos.
HU3 — Tablero Jira	É1 Infraestructura	✓ LISTO	Flujo de trabajo ágil configurado: To Do → En Progreso → Revisión → Listo. Cada tarea tiene criterio de terminación definido.
HU4 — Base de Datos	É1 Infraestructura	■ EN PRUEBA	Base de datos PostgreSQL con PostGIS habilitado. Tabla de municipios creada. Pendiente: cargar datos reales de población y geometrías.
HU5 — Extracción de Datos	É2 ETL	■ EN CURSO	Scripts que descargan datos del IDEAM e INS. Los archivos llegan pero aún no se han revisado las columnas disponibles.
HU6 — Limpieza	É2 ETL	■ PRÓXIMO	Normalizar fechas, nombres de columnas y valores vacíos. Marcar el período COVID (mar-2020 a dic-2021) como atípico.

HU7 — Tabla Maestra	É2 ETL	■ PRÓXIMO	Cruzar datos de salud + ambiente usando el código del municipio y la semana epidemiológica como llaves de unión.
HU8 — Carga en BD	É2 ETL	■ PRÓXIMO	Guardar la Tabla Maestra en PostgreSQL para que la API pueda consultarla eficientemente.

Lo que ya funciona técnicamente:

- ✓ La API responde en **http://localhost:8000/health** con estado 200 OK
- ✓ La base de datos PostgreSQL + PostGIS levanta automáticamente con Docker
- ✓ El archivo **init.sql** crea la estructura de tablas al iniciar el contenedor
- ✓ El **docker-compose** orquesta API + Base de Datos con verificación de salud automática
- ✓ El documento **ADR** justifica las decisiones técnicas ante el jurado
- ✓ El **tablero Jira** tiene el flujo ágil configurado con Definition of Done activo

3. ¿Qué toca hacer en el Sprint 2?

El Sprint 2 es el más importante del proyecto: define si el modelo de IA tendrá datos de calidad suficiente. **Sin datos limpios y bien cruzados, no hay modelo.** El objetivo es completar el pipeline de datos de punta a punta: desde la descarga hasta la carga en la base de datos, listo para el análisis exploratorio.

HU	Objetivo	Entregable concreto
HU5 completar	Abrir cada archivo descargado y confirmar que tiene las columnas clave: código del municipio (DIVIPOLA), fecha y PM2.5 o código de enfermedad.	Reporte de exploración: lista de columnas disponibles por dataset.
HU6	Limpiar los datos: fechas al formato YYYY-MM-DD, nombres de columnas en minúsculas, valores vacíos marcados, y agregar columna periodo_pandemia.	Archivos CSV limpios guardados en /data/processed/
HU7	Cruzar los datos de IRA con los datos de calidad del aire usando el código del municipio y la semana epidemiológica como punto de unión.	Tabla Maestra: un solo dataset con columnas de salud + ambiente.
HU8	Cargar la Tabla Maestra en PostgreSQL para que la API pueda consultarla sin necesidad de volver a procesar los archivos CSV.	Tabla fact_riesgo_territorial poblada y consultable en la base de datos.

■ Punto clave del Sprint 2: Manejo del período COVID-19

Los datos del SIVIGILA entre **marzo 2020 y diciembre 2021** son atípicos por la pandemia. Durante la limpieza (HU6) se debe agregar una columna **periodo_pandemia = Verdadero/Falso**. Esto le enseña al modelo que ese período fue excepcional y evita que confunda una emergencia global con un brote local normal. Es una fortaleza del modelo, no una debilidad.

4. ¿Cómo está organizado el sistema?

El sistema tiene 4 capas. Cada capa tiene una responsabilidad clara y se comunica con la siguiente. El equipo trabaja de abajo hacia arriba.

Capa	¿Qué hace?	Tecnología	Estado
------	------------	------------	--------

1. Datos	Descarga datos del SIATA, DANE e INS y los guarda como archivos CSV con una marca de tiempo.	Python + Pandas SODA2 API	■ En progreso
2. Base de Datos	Almacena los datos limpios y los polígonos de los municipios para hacer consultas espaciales rápidas.	PostgreSQL + PostGIS (Docker)	✓ Operativo
3. API (Backend)	Recibe preguntas del tablero y responde con datos del mapa y alertas en formato GeoJSON.	FastAPI (Python) (Docker)	✓ Walking skeleton
4. Tablero (Frontend)	Muestra el mapa del Valle de Aburrá con colores según nivel de riesgo y los KPIs de salud.	Streamlit + Leaflet	■ Pendiente

5. ¿De dónde vienen los datos?

VitalRisk AI usa únicamente fuentes oficiales del gobierno colombiano. Todos los datos son públicos y gratuitos.

Tipo de dato	Fuente oficial	¿Qué aporta al modelo?	Acceso
Calidad del Aire (PM2.5 / PM10)	SIATA + IDEAM	El factor ambiental principal que dispara los casos de IRA. A más contaminación, más enfermos.	SIATA: radicado 021682 IDEAM: datos.gov.co
Casos de IRA (la enfermedad)	SIVIGILA — INS	La variable que el modelo debe predecir: cuántos casos de infección respiratoria habrá la próxima semana.	Disponible en datos.gov.co
Población y pobreza (NBI)	DANE — CNPV 2018	Indica qué municipios son más vulnerables al mismo nivel de contaminación. Una comunidad pobre en zona contaminada tiene más riesgo.	Disponible en datos.gov.co
Meteorología (temperatura/humedad)	IDEAM	Variables de control: la lluvia limpia el aire, el frío agrava la IRA. Son necesarias para que el modelo no confunda causas.	Disponible en datos.gov.co
Geometría de municipios	DANE — DIVIPOLA	Los polígonos del mapa para colorear cada municipio según su nivel de riesgo.	GeoJSON público DANE

6. ¿Por qué esto importa y por qué vamos bien?

Cinco razones concretas por las cuales el proyecto es sólido y tiene posibilidades reales en el concurso:

■ Somos el 'SaluData del Valle de Aburrá'

El Observatorio de Salud de Bogotá (SaluData) es el caso de éxito más reconocido del concurso en el reto de salud. Usa exactamente la misma arquitectura que planteamos: fuentes clínicas + sociales + ambientales → base de datos → API → alertas. VitalRisk AI es ese sistema, pero para Antioquia, donde hoy no existe nada parecido.

■ La infraestructura técnica ya nos diferencia

Tener Docker + PostGIS + FastAPI funcionando desde el Sprint 1 es algo que la mayoría de equipos no logra. Proyectos ganadores como ViaVisión y TERRIDATA usaron exactamente este stack. El jurado lo reconoce como señal de madurez técnica real.

■ El IPT es nuestro diferenciador científico

No somos solo un tablero de datos. El Índice Preventivo Territorial (IPT) es un indicador compuesto original que clasifica municipios en riesgo bajo, medio y alto combinando datos ambientales, epidemiológicos y socioeconómicos. Ningún sistema público hace esto hoy para el Valle de Aburrá.

■ Los datos de 2018-2023 son suficientes y el COVID no es problema

Cinco años de datos son robustos para el modelo. El período COVID (2020-2021) no elimina los datos: se maneja marcando esos registros con una variable especial, lo que en realidad le enseña al modelo a reconocer perturbaciones externas. Es una fortaleza metodológica, no una debilidad.

■ Tenemos plan B para los datos del SIATA

Los datasets de calidad del aire del IDEAM en datos.gov.co cubren el Valle de Aburrá desde 2011 y ya están disponibles. Mientras llega la respuesta del SIATA (radicado 021682 ya registrado), construimos el pipeline con IDEAM. Cuando llegue el SIATA, simplemente enriquece la capa existente sin reescribir código.

7. Hoja de ruta del proyecto (3 meses)

El concurso dura 3 meses. Así están distribuidas las épicas:

MES 1 — Integración	MES 2 — IA y Visualización	MES 3 — Despliegue y Demo
✓ Infraestructura Docker ✓ Base de datos PostGIS ■ Pipelines ETL (ahora) ■ Análisis exploratorio ■ Cálculo del IPT	■ Modelo XGBoost ■ Motor de alertas ■ API geoespacial ■ Mapa interactivo ■ Panel de KPIs	■ Pruebas de integración ■ Despliegue en la nube ■ Datos semilla para demo ■ Pitch Deck ■ Defensa técnica