

VitalRisk AI

Resultados del Modelo Predictivo XGBoost — Epica 4

Sistema Inteligente de Vigilancia Preventiva Territorial en Salud
Prediccion de Brotes de IRA — Antioquia 2018-2023

RMSE Test

1.7399

casos/mun-semana

R2 Test

0.607

varianza explicada

Mejora Naive

+16.2%

vs baseline naive

Features

12

seleccionadas por votacion

Equipo 326

Datos al Ecosistema 2026 — IA para Colombia (MinTIC)
Julio 2026

1. Contexto del Problema de Modelado

VitalRisk AI predice brotes de Infeccion Respiratoria Aguda (IRA) con una semana de anticipacion para los 103 municipios de Antioquia con registro epidemiologico, permitiendo que las autoridades de salud publica activen protocolos preventivos antes de que el brote ocurra.

Caracterizacion del problema de ML

Dimension	Valor observado	Implicacion para el modelo
Tipo de tarea	Regresion supervisada	Predecir casos_ira_total semana t+1 (entero >= 0)
Tamano del dataset	807 registros (910 - ultimas semanas)	Dataset pequeno → regularizacion fuerte
Distribucion del target	Asimetrica (skew=1.66, max=13)	No normal → Spearman mas apropiado que Pearson
Nulos en features	23-30% en variables ambientales	XGBoost maneja NaN nativamente (tree_method=hist)
Autocorrelacion temporal	DW=2.89 lag1 r=0.852	Serie tiene memoria fuerte → lags son criticos
Heterogeneidad espacial	103 municipios muy diferentes	Un modelo global aprende interacciones no lineales
Periodo atipico	2021: 53 filas (pandemia COVID)	Flag periodo_pandemia = True en validation

Nota: el split cronologico estricto (Train: 2018-2020 | Val: 2021 | Test: 2022-2023) garantiza que el modelo nunca aprende del futuro para predecir el pasado, simulando el escenario real de produccion.

Split cronologico — distribucion de datos

Particion	Anos	Filas	% del total	Pandemia	Proposito
Train	2018-2020	498	61.7%	61 filas	Entrenamiento del modelo — aprender patrones normales + inicio pandemia
Validation	2021	53	6.6%	53 filas (100%)	Ajuste de HP — NOTA: 100% pandemia, RMSE alto es esperado
Test	2022-2023	256	31.7%	0 filas	Evaluacion final — comportamiento post-pandemia (mas relevante para prod.)

Justificacion epidemiologica del split

Para datos de vigilancia en salud se recomienda retener al menos 2 anos como test para capturar la variabilidad post-pandemia. El validation en 2021 es intencionalmente el periodo mas dificil (100% pandemia), lo que explica por que todos los modelos tienen R2 negativo en validacion — estan siendo evaluados en el periodo mas atipico del dataset. El test en 2022-2023 es la metrica mas representativa para produccion.

2. Baseline Naive y Feature Engineering

2.1 Baseline Naive (criterio minimo exigible)

El baseline mas simple predice que la semana t+1 tendra los mismos casos que la semana t (persistencia). Si XGBoost no supera este umbral, el modelo no aporta valor sobre una prediccion trivial.

RMSE Naive (benchmark)

2.0763

casos/municipio-semana

MAE Naive

1.0768

casos/municipio-semana

RMSE XGBoost Test

1.7399

SUPERA el baseline ✓

Mejora vs Naive

+16.2%

en RMSE test

2.2 Feature Engineering — variables derivadas

Se generaron 4 nuevas features que capturan patrones temporales y estacionales sin introducir data leakage:

Feature	Tipo	Formula / Fuente	Justificacion
semana_sin	Estacionalidad	$\sin(2 \cdot \pi \cdot \text{semana_epi} / 52)$	Captura patron bimodal IRA (picos sem. 10-15 y 35-45) sin tratar semana_epi como ordinal
semana_cos	Estacionalidad	$\cos(2 \cdot \pi \cdot \text{semana_epi} / 52)$	Complemento: la semana 52 no es 'mayor' que la semana 1
media_hist_mun_sem	Contexto historico	Promedio casos municipio×semana (solo train 2018-2020)	Permite saber cual es la linea base local para esa semana del ano — sin leakage
desviacion_vs_historico	Senyal de alerta	$(\text{casos_actual} - \text{media_hist}) / \text{media_hist} \cdot 100$	Misma senyal que activa las alertas en HU15 — ya calculada para el modelo

Resultado de la comparacion pre/post Feature Engineering (Gradient Boosting en validacion):

Metrica	Baseline Naive	Pre-FE (val)	Post-FE (val)	Mejora FE
RMSE	2.0763	4.4557	3.5821	+19.6% (FE vs Pre-FE)
MAE	1.0768	3.9102	2.9582	+24.3%

Nota: el RMSE Pre-FE y Post-FE son superiores al naive porque se evaluan en 2021 (100% pandemia). La mejora del FE (+19.6%) es interna al periodo de validacion atipico.

3. Seleccion de Features por Votacion

Se aplicaron 7 metodos de seleccion de features. Cada metodo propuso un ranking y se encontro el k optimo que minimiza RMSE en validacion. Las features que aparecen en mas metodos son las mas estables y confiables para el modelo — metodologia identica a la vista en clase de Fundamentos de IA.

Metodo	Features sel.	Justificacion
ANOVA F-test (f_regression)	3	Mide si la varianza entre grupos es mayor que dentro — adaptado a regresion
Informacion Mutua	15	No asume distribucion normal — apropiado dado que datos no son normales (Shapiro $p<0.001$)
Spearman HU9	3	Ranking basado en correlaciones calculadas en NB05 — especifico del proyecto
L1 Lasso	15	Penalizacion L1 fuerza a cero coeficientes de features irrelevantes
Random Forest Importance	3	Importancia por reduccion de impureza — mas robusto que un solo arbol
Gradient Boosting Importance	3	Mismo algoritmo que XGBoost — el ranking mas relevante para nuestro modelo
RFECV (KFold=3, sin shuffle)	19	Eliminacion recursiva con CV temporal — KFold sin shuffle respeta el orden temporal

Tabla de estabilidad — votos por feature

Se contaron cuantos metodos seleccionaron cada feature (excluyendo 'Todos los rasgos'). Las features con mas votos son las mas robustas. Umbral de seleccion: $\geq$ mitad de metodos (≥ 4 votos) + features criticas de HU9.

Feature	Votos (de 7)	Tipo	Seleccionada
media_hist_mun_sem	7/7	FE temporal	SI ✓
casos_ira_total	7/7	Epidemiologica	SI ✓
casos_ira_lag1	7/7	Lag temporal	SI ✓
humedad_avg	3/7	Ambiental	SI ✓
desviacion_vs_historico	3/7	FE temporal	SI ✓
nbi	2/7	Socioecon.	NO
ipm_pct	2/7	Socioecon.	SI (critica HU9)
pm25_avg	2/7	Ambiental	SI (critica HU9)
pm25_lag1	2/7	Ambiental lag	SI (critica HU9)
icv_seg_social	1/7	Socioecon.	SI (critica HU9)
icv_score	1/7	Socioecon.	SI (critica HU9)
semana_sin / semana_cos	1/7	FE estacional	SI (critica FE)

Features seleccionadas para el modelo final: 12 | 3 seleccionadas por todos los metodos | 9 adicionales por criterio epidemiologico (HU9) o feature engineering

4. Comparacion de Modelos y Resultados XGBoost

4.1 Comparacion de modelos en validacion

Se probaron 7 modelos con las 12 features seleccionadas sobre el validation set. Ninguno supero el baseline naive en validacion — esperado porque el validation es 100% periodo pandemia (2021). La seleccion de XGBoost se basa en su capacidad de manejo nativo de NaN, regularizacion L1/L2 y explicabilidad SHAP.

Modelo	RMSE Val	MAE Val	R2 Val	Notas
Extra Trees	3.4747	2.9334	-0.646	Mejor RMSE en validacion
Gradient Boosting	3.5821	2.9582	-0.749	Cercano a XGBoost
Decision Tree	3.7608	2.9516	-0.928	Tiende a sobreentrenar
KNN Regressor	3.7499	3.2755	-0.917	No extrapola bien
Random Forest	3.7708	3.2098	-0.938	Robusto pero sin SHAP
XGBoost	3.8100	3.1419	-0.979	Seleccionado: NaN nativo + SHAP + regularizacion
AdaBoost	3.8693	3.3145	-1.041	Sensible a outliers
Baseline Naive	2.0763	1.0768	N/A	TODOS peor que naive en val.

4.2 Hiperparametros optimos XGBoost (Grid Search sobre validacion)

Hiperparametro	Valor optimo	Rango evaluado	Justificacion
max_depth	3	[3, 4, 6]	Profundidad baja → mayor regularizacion, menos overfitting
learning_rate	0.05	[0.05, 0.1, 0.15]	Tasa baja + mas estimadores = mejor convergencia
n_estimators	200	[100, 200, 300]	Balance entre sesgo y varianza
subsample	1.0	[0.8, 1.0]	Sin submuestreo → dataset pequeno (807 filas)
colsample_bytree	0.8	[0.8, 1.0]	80% features por arbol → regularizacion adicional
tree_method	hist	Fijo	Unico metodo nativo para NaN en XGBoost

5. Metricas Finales — Evaluacion en Test (2022-2023)

El modelo fue entrenado con Train+Val (2018-2021) y evaluado por primera vez en el Test (2022-2023). Esta es la metrica definitiva que determina si el modelo es util en produccion post-pandemia.

RMSE — Test

1.7399

casos/mun-semana

MAE — Test

1.0295

casos/mun-semana

R2 — Test

0.607

varianza explicada

Mejora vs Naive

+16.2%

criterio HU14 cumplido

Validacion cruzada temporal (TimeSeriesSplit — 5 folds)

Se aplico TimeSeriesSplit con 5 folds sobre Train+Val para validar la estabilidad del modelo a lo largo del tiempo. La alta varianza entre folds es esperada en datos epidemiologicos con cambios de regimen (pandemia).

Fold	RMSE	Periodo aprox.	Interpretacion
1	4.4306	Train: 2018, Test: 2019	Pocos datos de entrenamiento — municipios con poca historia
2	1.0329	Train: 2018-2019, Test: 2020 inicio	Pre-pandemia bien cubierto — modelo funciona bien
3	1.1465	Train: 2018-2020 (pre), Test: 2020 medio	Similar al fold 2 — estabilidad en periodo normal
4	0.2886	Train completo pre-pandemia, Test: inicio pandemia	Caida real de casos → facil predecir 'pocos casos' (no indica modelo perfecto)
5	2.6751	Train con pandemia, Test: post-pandemia	Mas dificil — cambio de regimen. Mas representativo de produccion
MEDIA	1.9147	CV global	Mejor que naive (2.0763) — criterio cumplido ✓
STD	1.4778	—	Alta varianza esperada por cambio de regimen epidemiologico


Resumen de criterios de aceptacion HU14:

Criterio	Meta	Resultado	Estado
RMSE test < RMSE naive	< 2.0763	1.7399	CUMPLIDO ✓
MAE test	< 1.0768	1.0295	CUMPLIDO ✓
R2 test > 0	> 0	0.607	CUMPLIDO ✓
RMSE CV medio < naive	< 2.0763	1.9147	CUMPLIDO ✓
Modelo serializado (.pkl)	Si	233.6 KB	CUMPLIDO ✓
Metricas en JSON	Si	Si	CUMPLIDO ✓
Features documentadas	Si	12 feat.	CUMPLIDO ✓

6. Feature Importance y Analisis de Residuales

6.1 Feature Importance XGBoost (gain normalizado)

La feature importance de XGBoost alimenta directamente la columna variable_causal en alertas_territoriales (HU15). Cuando se genera una ALERTA_ROJA, el sistema indica cual feature contribuyo mas a la prediccion de brote en ese municipio especifico esa semana.



Los dos primeros features (casos_ira_lag1 y casos_ira_total) dominan con 0.388 y 0.360 respectivamente, confirmando que la autocorrelacion temporal es la senal mas fuerte para predecir brotes. Las features ambientales (pm25_lag1, humedad_avg) y socioeconomicas (icv_seg_social) aportan informacion complementaria que mejora la prediccion en municipios con datos climaticos disponibles.


6.2 Hallazgos del analisis de residuales

Hallazgo	Valor / Observacion	Implicacion
Media de residuos	-0.339 (cercana a 0)	Sin sesgo sistematico — el modelo no sobre ni subestima en promedio
Distribucion residuos	Asimetrica con colas pesadas	Consistent con datos de conteo (IRA). Poisson/NegBinomial podria ajustar mejor en iteraciones futuras
R2 = 0.607	61% varianza explicada	Razonable para epidemiologia con 30% NaN ambiental y solo 807 registros
Q-Q plot	Desviaciones en colas	Valores extremos (brotes severos) son mas dificiles de predecir — comportamiento esperado
Casos predichos max	~12 casos	El modelo predice el rango real observado (1-13 casos post-winsorización)

Anexo: Graficas del Notebook 07 — NB07


Curvas de Validacion — RMSE vs Numero de Features (6 metodos)

Cada metodo de seleccion de features propuso un ranking. Se evaluo el RMSE en validacion para k=1 hasta k=31 features. La linea roja muestra el baseline naive (2.08).




Heatmap de Cobertura — Features Seleccionadas por cada Metodo

Azul = feature seleccionada por ese metodo. Las 3 features seleccionadas por todos los metodos son: media_hist_mun_sem, casos_ira_total, casos_ira_lag1.




Comparacion de Modelos — RMSE en Validation Set

Todos los modelos superan el baseline naive en test (2022-2023) pero no en validacion (2021, 100% pandemia). XGBoost fue seleccionado por su manejo nativo de NaN y explicabilidad SHAP.



Feature Importance XGBoost (gain normalizado)


casos_ira_lag1 (0.388) y casos_ira_total (0.360) dominan — la autocorrelacion temporal es la senal mas fuerte. icv_seg_social (0.048) es la variable socioeconomica mas importante.



Analisis de Residuales — XGBoost Final (Test 2022-2023)

Izquierda: distribucion de residuos con media=-0.339 (sin sesgo sistematico). Centro: scatter real vs predicho con $R^2=0.607$.

Derecha: Q-Q plot — desviaciones en colas son esperadas para datos de conteo (IRA).



7. Artefacto del Modelo y Proximos Pasos

7.1 Artefacto serializado — modelo_xgboost_vitalrisk.pkl

El artefacto .pkl es lo que el backend FastAPI carga para inferencia en produccion. Contiene todos los elementos necesarios para reproducir exactamente las predicciones sin re-entrenar.

Campo en el .pkl	Contenido	Uso en produccion
modelo	XGBRegressor entrenado con train+val (2018-2021)	modelo.predict(X) → prediccion de casos t+1
features	Lista de 12 features en orden correcto	Garantiza que el API construye el vector de features en el orden exacto
fill_values	Mediana de cada feature en train+val	Imputa NaN en tiempo real para municipios sin dato ambiental esa semana
mejores_params	max_depth=3, lr=0.05, n_est=200, ss=1.0, cbt=0.8	Documentacion — permite re-entrenar con los mismos HP
metricas_test	RMSE=1.74, MAE=1.03, R2=0.607, mejora=+16.2%	La API puede exponer estas metricas en /health o /modelo/info
cv_temporal	RMSE por fold [4.43, 1.03, 1.15, 0.29, 2.68]	Transparencia metodologica para el jurado y documentacion tecnica
feature_importance	Diccionario feature→importance (gain)	Alimenta variable_causal en alertas_territoriales (HU15)

Tamano del artefacto: 233.6 KB | Ruta: models/modelo_xgboost_vitalrisk.pkl

7.2 Proximas HUs — Epica 4 (pendientes)

HU	Nombre	NB	Descripcion	Estado
HU14	Evaluacion SHAP	08	SHAP values para explicacion local de cada prediccion. Alimenta variable_causal en alertas_territoriales.	PENDIENTE
HU15	Motor alertas	09	Generar ALERTA_VERDE/NARANJA/ROJA por municipio. Umbral 30% = percentil 92 historico (NB05). Escribir en alertas_territoriales.	PENDIENTE

7.3 Hoja de ruta restante — 12 dias al 13 de julio

Epica / HU	Descripcion	Fecha objetivo	Bloqueante
Epica 3 — HU11 (cerrada)	IPT calculado, cargado en PostGIS	Completada	Ninguno
Epica 4 — HU14 SHAP	Explicabilidad local del modelo	2 julio	Modelo .pkl (ya disponible)
Epica 4 — HU15 Motor alertas	alertas_territoriales poblada	3 julio	SHAP completado
Epica 5 — API FastAPI	Endpoints geoespaciales + inferencia	6 julio	Motor alertas (HU15)
Epica 6 — QA + despliegue	Tests de integracion + cloud	9 julio	API funcionando
Epica 7 — Pitch + defensa	Presentacion + demo + docs finales	13 julio	Sistema desplegado

VitalRisk AI — Equipo 326 | Datos al Ecosistema 2026 — IA para Colombia (MinTIC) | HU12 + HU13 completadas el 1 de julio de 2026